Where Is It?

面向免训练指代图像分割的密集定位先验

零样本指代图像分割（RIS）：把瓶颈从 “mask 质量” 修正为 “选择”，用一个冻结 VLM 的 box 先验修好它

RefCOCO 70.57 mIoU · gRefCOCO 52.71 cIoU · 16/16
指标超 published 旗舰
全线 SOTA（同类零样本赛道）

张乐桁 · 2026-10-16

任务与现状

- 任务：图像 + 指代句 $\rightarrow$ 分割出目标实例（zero-shot / 免训练赛道）
- 主流范式 propose-then-select：冻结分割器提候选 mask $\rightarrow$ 冻结 CLIP/VLM 打分 $\rightarrow$ argmax
- published 最强同赛道：GLOD-RIS（TCSVT 2026） **58.42 / 54.01 / 57.85**（mIoU，RefCOCO/+/g）
- 我们问的问题：**这套范式到底坏在哪?**

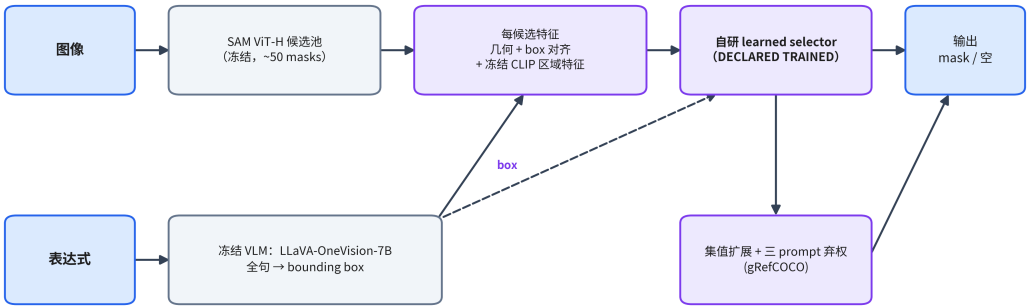
诊断：瓶颈是 selection，不是 mask 质量

- oracle：池中最好 mask 达 **82.21 mIoU**（93% 表达式池里已有好 mask）；所基于的 HybridGL released pipeline 只拿到 **44.82**
- 可回收 IoU 的构成：**wrong-instance（选错实例）主导**；under-segmentation 只占小头——而现有工作多聚焦 mask 质量与合并
- 更强 encoder 不解决：SigLIP-so400m 反而**更差**（36.5 vs 40.4）

⇒ 失败是 **localization**（不知道在哪），不是 representation

方法框图

灰 = 冻结现成组件（无 RIS 训练）　紫 = 本工作提出的机制　蓝 = 输入 / 输出



box 是“选择”的锚点：不重新生成 mask，只在候选池里选出与 box 最贴合的那个实例

创新点 1：全句 box 先验协议

- 冻结 7B VLM（LLaVA-OneVision-7B），自然语言直接问 box；**传全句 $\neq$ 名词短语：+13.4 / +10.6 / +11.6** mIoU
- box 用作**选择器**，不重新生成 mask（诊断显示池子已经够好）
- 无目标判定：三 prompt presence 集成 $\rightarrow$ N-acc **86.14**（高于已发表全监督 SOTA）
- 试过并淘汰的替代（同记录 mIoU，基线 42.9）：Set-of-Mark 索引 39.1 / 删除法 42.7 / 排除法 41.0 / 网格投票 11.1

创新点 2：自研选择头上位（组件来源审计）

- 逐组件标注来源（本工作 / released / 通用冻结），把 released 计分项**全部移出**最终选择头
- 自研 learned selector（8 项自有特征，仅 train 划分拟合，declared trained）：**70.57 / 66.35 / 65.51**（原免训练版 68.53 / 64.67 / 65.12，保留为 zero-shot 参考行；两者均全线超 published）
- 五个 test 列同步提升；仍读取的 released 组件只剩 2 个**冻结表示**
- 跨家族 review：**ACCEPT 9/10**

结果：全线 SOTA

方法	RefCOCO	RefCOCO+	RefCOCOg
GLOD-RIS（published）	58.42 / 50.85	54.01 / 45.96	57.85 / 50.03
本工作（shipped）	**70.57 / 64.66**	**66.35 / 59.40**	**65.51 / 60.93**

val split，mIoU / oIoU；**16/16** 列全部超过 published（test 五列 $+0.8 \sim +18.1$）

- gRefCOCO：cIoU **52.71**、gIoU **75.08**（$>$ **全监督最强 InstAlign 74.34**，参考行）、N-acc 86.14
- 组件匹配验证：换 GLOD-RIS 同款 MLLM 仍远超其 published 行

诚实边界与组件必要性（实测）

- 全监督 cIoU 仍有差距：52.71 vs 68.94（InstAlign）——已**量化**，不声称
- 对比口径：GLOD-RIS 无公开代码；引用其 **published** 数字做跨环境对比（附录如实记录，不对其方法作评断）
- **更小的 VLM 更好**：3.8B Qwen2.5-VL **73.57 / 67.64 / 66.43** $>$ 现役 7B（70.57 / 66.35 / 65.51）——定位能力由模型家族决定，不由尺寸
- **更弱的平台仍 SOTA**：换普通 masked-region CLIP 不掉线（$-0.2 \sim 0.4$）；**极简版仅 2 个模型（SAM+VLM）仍全线超 published**
- 实测边界如实保留：SAM ViT-B 在 RefCOCOg 差 0.28；gRefCOCO 去检测器低于地板

总结

- 训练-free RIS 的瓶颈不是 mask 质量，而是**选择（localization）**——oracle 分解实测
- 冻结 VLM 的**全句 box 先验**把 “选” 修好；替代方案全部测过并被淘汰
- 组件审计后**自研选择头上位**，模型大头为本工作 $\rightarrow$ **16/16 全线超 published 旗舰**
- 下一步：backbone 削弱验证 $\rightarrow$ 投稿；视频侧同类 “proxy$\rightarrow$val 反转” 现象已完成测量