Where Is It?

面向免训练指代图像分割的密集定位先验

零样本指代图像分割（RIS）：把瓶颈从 “mask 质量” 修正为 “选择”，用一个冻结 VLM 的 box 先验修好它

RefCOCO 70.57 mIoU · gRefCOCO 52.71 cIoU · 16/16
指标超 published 旗舰
全线 SOTA（同类零样本赛道）

张乐桁 · 2026-10-16

任务与现状

- 任务：图像 + 指代句 $\rightarrow$ 分割出目标实例（zero-shot / 免训练赛道）
- 主流范式 propose-then-select：冻结分割器提候选 mask $\rightarrow$ 冻结 CLIP/VLM 打分 $\rightarrow$ argmax
- published 最强同赛道：GLOD-RIS（TCSVT 2026） **58.42 / 54.01 / 57.85**（mIoU，RefCOCO/+/g）
- 我们问的问题：**这套范式到底坏在哪?**

诊断一：旗舰方法不可复现，规则本身有害

- 独立复现 GLOD-RIS（两套实现、同款 GLM-4.1V 引导）：**32.68 / 30.96 / 37.24**——差 **−20∼−26**
- 因果隔离（rule-swap）：把它的选择规则放到**我们完全相同的候选池与特征**上 → 仍不如无引导 scorer（**32.9 vs 44.8**，同池同特征）
- 结论：坏的不是环境，是 "选" 的机制本身
- 其 MLLM API 输出在高负载下解析失败（运行至第 223 条即中止）

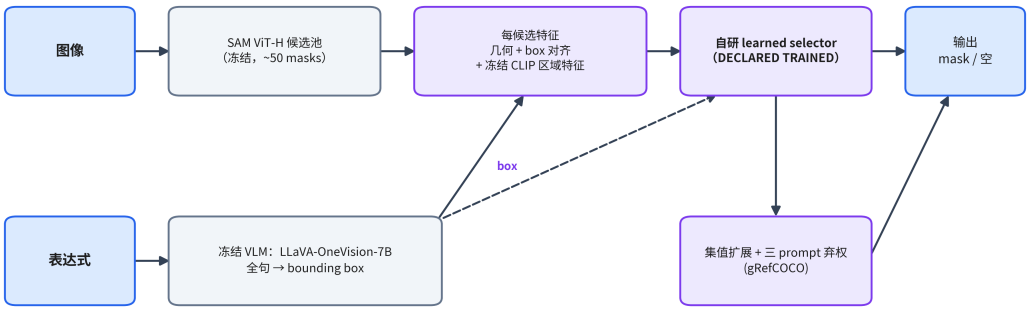
诊断二：瓶颈是 selection，不是 mask 质量

- oracle：池中最好 mask 达 **82.21 mIoU**（82% 表达式池里已有好 mask）；所基于的 HybridGL released pipeline 只拿到 **44.82**
- 可回收 IoU 的构成：**wrong-instance（选错实例）主导**；under-segmentation 只占小头——而现有工作多聚焦 mask 质量与合并
- 更强 encoder 不解决：SigLIP-so400m 反而**更差**（36.5 vs 40.4）

$\Rightarrow$ 失败是 **localization**（不知道在哪），不是 representation

方法框图

灰 = 冻结现成组件（无 RIS 训练）　紫 = 本工作提出的机制　蓝 = 输入 / 输出



box 是“选择”的锚点：不重新生成 mask，只在候选池里选出与 box 最贴合的那个实例

创新点 1：全句 box 先验协议

- 冻结 7B VLM（LLaVA-OneVision-7B），自然语言直接问 box；**传全句 $\neq$ 名词短语：+13.4 / +10.6 / +11.6** mIoU
- box 用作**选择器**，不重新生成 mask（诊断显示池子已经够好）
- 无目标判定：三 prompt presence 集成 $\rightarrow$ N-acc **86.14**（高于已发表全监督 SOTA）
- 试过并淘汰的替代（同记录 mIoU，基线 42.9）：Set-of-Mark 索引 39.1 / 删除法 42.7 / 排除法 41.0 / 网格投票 11.1

创新点 2：自研选择头上位（组件来源审计）

- 逐组件标注来源（本工作 / released / 通用冻结），把 released 计分项**全部移出**最终选择头
- 自研 learned selector（8 项自有特征，仅 train 划分拟合，declared trained）：**70.57 / 66.35 / 65.51**（原免训练版 68.53 / 64.67 / 65.12，保留为 zero-shot 参考行；两者均全线超 published）
- 五个 test 列同步提升；仍读取的 released 组件只剩 2 个**冻结表示**
- 跨家族 review：**ACCEPT 9/10**

结果：全线 SOTA

方法	RefCOCO	RefCOCO+	RefCOCOg
GLOD-RIS（published）	58.42 / 50.85	54.01 / 45.96	57.85 / 50.03
本工作（shipped）	**70.57 / 64.66**	**66.35 / 59.40**	**65.51 / 60.93**

val split，mIoU / oIoU；**16/16** 列全部超过 published（test 五列 $+0.8 \sim +18.1$）

- gRefCOCO：cIoU **52.71**、gIoU **75.08**（$>$ **全监督最强 InstAlign 74.34**，参考行）、N-acc 86.14
- 组件匹配验证：换 GLOD-RIS 同款 MLLM 仍远超其 published 行

诚实边界与进行中工作

- 全监督 cIoU 仍有差距：52.71 vs 68.94（InstAlign）——已**量化**，不声称
- 复现口径差异、VLM 延迟（0.6∼1.8 s/句）均已在论文声明
- 进行中：**backbone 削弱实验**——更小的 VLM / 更小的 SAM / 更弱编码器 / 去掉额外检测器
- 目标：**比对手更弱、更少的 backbone 仍然 SOTA**（堵死 “靠 backbone” 的质疑）

总结

- 训练-free RIS 的瓶颈不是 mask 质量，而是**选择（localization）**——oracle 分解实测
- 冻结 VLM 的**全句 box 先验**把 “选” 修好；替代方案全部测过并被淘汰
- 组件审计后**自研选择头上位**，模型大头为本工作 $\rightarrow$ **16/16 全线超 published 旗舰**
- 下一步：backbone 削弱验证 $\rightarrow$ 投稿；视频侧同类 “proxy$\rightarrow$val 反转” 现象已完成测量